

新员工转正答辩

SOC 内容安全审核 · 小语种能力储备

内容安全运营中心

2026 年度转正答辩

目录

01 自我介绍

个人背景、教育经历与工作信息概览

02 主要工作内容及输出

全球多地区小语种内容安全能力储备与核心成果

03 试用期总结与思考

工作成果回顾、经验沉淀与个人成长反思

04 下一步工作目标与计划

未来工作方向、阶段目标与实施路径

自我介绍

个人背景与工作经历概览

01

个人信息



请补充姓名

部门 请补充 项目组 请补充 入职时间 请补充



毕业院校

请补充



研究方向

请补充



导师

请补充



直接主管

请补充

博士期间论文发表

[1] 请补充论文标题
期刊 / 会议名称, 年份

[2] 请补充论文标题
期刊 / 会议名称, 年份

[3] 请补充论文标题
期刊 / 会议名称, 年份

[4] 请补充论文标题
期刊 / 会议名称, 年份

主要工作内容及输出

全球多地区小语种内容安全能力储备与核心工作成果

02

两大核心工作方向



小语种内容安全 审核能力储备

覆盖 5 大区域、8+ 个国家，构建多语种内容安全审核标准、人才体系与工具平台，实现从 0 到 1 的小语种审核能力落地。

- 语种调研
- 人才储备
- 标准建设
- 质量管控



内容安全审核 智能体的探索

探索 AI 智能体在内容安全审核场景中的应用，提升审核效率与准确性，降低人工成本，构建智能化审核能力。

- 智能审核
- 自动化 Pipeline
- 人机协同
- 效率提升

工作输出与学习成果总览

试用期内核心交付物、学习成长与能力建设成果概览

 小语种内容安全能力储备

覆盖 5 大区域 · 8 个国家

工作内容	具体工作	输出成果
法律法规调研	8 国内容审核法律法规与文化禁忌分析	8 份各国法规调研文档 · 违规分类标签体系
数据集建设	公开数据集收集 + 8 国论坛数据爬取 + 清洗标注	30+ 公开数据集 · 374 万爬取 · 457K 清洗样本 · 3 份 CSV
敏感词库	公开词库 + Juror B/C 实时推理双轨收集	110,847 条关键词 (单字 13,932 / 词组 96,915) · 8 国标签
模型调研	多语言编码器 / 护栏模型 / 本土 LLM 全面调研	30+ 论文研读 · 16 编码器 + 12 护栏模型对比报告
模型训练	冻结底层 8 层 + LoRA r=16 双方案 · 8 国独立训练	8 国 Adapter 模型 (~25MB/国) · 训练评估报告

 内部培训与考核

培训 / 考试	结果
内容安全审核规范培训	✅ 通过
AI Agent 安全培训考核	✅ 通过
数据安全与隐私合规培训	✅ 通过

 内容审核智能体 POC

Multi-Agent Content Moderation

工作内容	具体工作	输出成果
系统架构	FastAPI + LangGraph 双层架构设计与实现	完整源码 + 架构文档 + 部署指南
审核 Pipeline	热路径 6 层预筛 + 冷路径 4 Agent DAG	文本三层漏斗 · 图像四步处理 Pipeline
AI Agent 安全	Agent 安全风险全景分析与威胁建模	Agent 安全洞察胶片 · 安全技术文档

 技术学习成果

学习方向	成果
多语言 NLP	30+ 论文 · 48+ 模型调研
Agent 工程	LangGraph / 6 种 LLM 后端
内容安全	8 国法规 · 三层分类体系
工程实践	6 大独立系统从零交付

Token 出海与内容安全

Token 正积极推进全球化战略，目前已覆盖 **请补充国家/地区** 等市场。

随着海外用户规模持续增长，平台内容呈现多语种、多文化、多地域的复杂特征，对内容安全审核能力提出了更高的要求。

小语种内容审核面临**人才稀缺**、**标准缺失**、**工具不足**三大核心挑战，构建体系化的小语种内容安全能力成为保障出海业务合规运营的关键课题。

亚太

中东

欧洲

非洲

南美



IMAGE

Token 出海市场分布图 / 全球业务覆盖地图

720 x 540

小语种内容安全能力储备的战略价值



保障出海业务合规

建立多语种审核标准，满足各地区法律法规与内容监管要求，降低合规风险



支撑全球化用户体验

积累小语种内容理解能力，确保跨地区内容安全策略的一致性与本地化平衡



构建可复用的能力体系

形成标准化的语种能力建设方法论，加速新市场覆盖，降低边际成本



提升组织核心竞争力

打造差异化的小语种内容安全壁垒，增强团队国际化运营能力与行业影响力

小语种覆盖国家与地区概览

覆盖 5 大区域、8 个重点国家，构建多语种内容安全能力矩阵

亚太

APAC

3 个国家

TH 泰国 泰语

佛教文化主导，王室相关内容审查极为严格

SG 新加坡 英 / 马 / 中 / 泰米尔

多元种族社会，种族与宗教议题高度敏感

ID 印度尼西亚 印尼语

全球最大穆斯林人口国，宗教审查要求极高

中东与欧洲

ME • EU

3 个国家

SA 沙特阿拉伯 阿拉伯语

严格教法国家，文化禁忌繁多，内容管控严苛

AE 阿联酋 阿拉伯语

中东互联网枢纽，多元外籍人口，内容合规要求严格

TR 土耳其 土耳其语

世俗化穆斯林国家，政治与民族问题敏感度高

非洲与南美

AF • LATAM

3 个国家

ZA 南非 英 / 南非语 / 祖鲁语等

多种族多语言社会，种族遗留与暴力内容突出

MX 墨西哥 西班牙语

天主教文化为主，毒品与暴力内容是审核重点

BR 巴西 葡萄牙语

多民族融合，暴力内容与虚假信息问题显著

⚠️ 主要挑战

人才稀缺 小语种审核人员招募困难

标准缺失 多语种审核标准从零建立

文化壁垒 本地文化理解门槛高

工具不足 小语种 NLP 能力薄弱

小语种内容安全能力建设方法论

四步构建 9 国审核能力 · 每一步产出直接赋能三层漏斗中的对应层级

① 各国法规政策与风俗调研

深入调研 9 国 AI 监管法规、内容审核法律要求、宗教文化禁忌与政治红线，提炼各国独有违规分类标签体系

输出 → 9 国合规报告 + 三层分类标签 (binary/coarse/fine)

② 数据集构建

HuggingFace 收集 68+ 公开数据集 + 自主爬取 11 国论坛内容，经清洗去重、陪审团标注、法官裁决后形成高质量训练数据

输出 → 573K 条清洗样本 + binary/coarse/fine 三层标注

③ 敏感词库建设

公开关键词数据集 + Juror B/C 推理实时提取双轨并进，去重、语种标注、翻译对齐、人工复核后统一入库

输出 → 110,847 条敏感词/词组 + 150K+ 备选词库 + 9 国标签

④ 模型训练与部署

基于 mDeBERTa-v3 / XLM-R 多语言底座，冻结底层 + LoRA 双方案微调 9 国分类模型，ONNX 导出离线部署

输出 → 9 国 LoRA Adapter (~25MB/国) + ONNX 模型 + 护栏/LLM 链路

三层审核漏斗 流量逐级收敛 · 计算成本递减

L1 · 敏感词库匹配 — 毫秒级

110,847 条敏感词/词组命中即拦截 · 零容忍类别直接阻断

← 来自 ③ 敏感词库建设 + ① 法规标签体系

100% 流量入口

未命中 ↓ 约 80% 流量

L2 · 多语言 BERT 分类 — ~20ms/条

mDeBERTa-v3 + 9 国 LoRA Adapter 微调 · 过滤 70–80% 合规内容

← 来自 ② 数据集训练 + ④ 模型部署 + ① 标签体系

~80% 流量

低置信度 20–30% ↓

L3 · 生成式护栏 / LLM 推理

ShieldGemma-2B · Qwen3-Guard 深度语义推理

← 来自 ④ 护栏/LLM 部署 + ① 合规标准

~20% 流量

→ 决策 Agent 聚合裁决

各国法规政策与风俗调研

在构建小语种内容审核能力之前，首先深入了解各国风俗习惯、法律法规与 AI 监管政策，明确内容审核的合规边界

调研维度



AI 法规与监管

各国人工智能法案、数据保护条例、平台内容责任法规



内容审核法律

仇恨言论、暴力内容、色情内容等各维度的法律界定



宗教与文化禁忌

伊斯兰教法、王室保护、种族和谐等敏感领域



语言与俚语特性

当地方言、网络黑话、隐晦表达的文化含义

工作输出

输出各国内容合规调研报告，涵盖 AI 法规、内容审核法律要求及文化敏感点，形成分类标签体系

TH 泰国

法规：《刑法》第112条、《计算机犯罪法》

审核重点：冒犯君主罪 (Lèse-majesté)、政治煽动

冒犯君主 政治颠覆 王室敏感 网络犯罪

SA 沙特阿拉伯

法规：《反网络犯罪法》《出版法》

审核重点：亵渎神明、反伊斯兰内容、道德风纪

亵渎神明 反伊斯兰教法 道德风纪

反王室

ZA 南非

法规：《防止仇恨犯罪与仇恨言论法案》

审核重点：严重种族歧视、排外攻击、暴力内容

种族歧视 排外攻击 暴力内容 仇恨言论

SG 新加坡

法规：《网络安全法》《维护种族和谐法》

审核重点：种族/宗教和谐、CMIO 框架攻击

种族和谐 宗教敏感 排外仇恨 虚假信息

AE 阿联酋

法规：《网络犯罪法》(Decree-Law No.34)

审核重点：宗教尊重、政治稳定、外籍人口合规

宗教尊重 政治稳定 文化多元 网络犯罪

MX 墨西哥

法规：《电信与广播法》《数字版权法》

审核重点：毒品暴力、有组织犯罪、选举虚假信息

毒品暴力 有组织犯罪 虚假信息

宗教敏感

ID 印度尼西亚

法规：《电子信息和交易法》(UU ITE)

审核重点：SARA 原则 (部落/宗教/种族/群体)

SARA 违规 宗教亵渎 族群仇恨

分裂主义

TR 土耳其

法规：TCK 299/301、《互联网法》第5651号

审核重点：侮辱国家/国父、分裂主义与恐怖组织

侮辱国家元首 分裂主义 恐怖宣传

民族冲突

BR 巴西

法规：《互联网民权框架》(Marco Civil)

审核重点：政治极端化、结构性种族主义

政治极端 种族主义 选举虚假 儿童保护

各国法规政策与风俗调研

覆盖 3 大区域 · 9 个国家，深入了解各国风俗、法规、AI 监管政策与内容审核合规边界

国家	法规与监管	审核重点	分类标签			
TH 泰国 亚太	《刑法》第112条 · 《计算机犯罪法》	冒犯君主罪 (Lèse-majesté) · 政治煽动与王室相关敏感内容 · 网络言论管控	冒犯君主	政治颠覆	王室敏感	网络犯罪
SG 新加坡 亚太	《网络安全法》 · 《维护种族和谐法》 · POFMA	种族/宗教和谐 (CMIO 框架) · 排外仇恨言论 · 虚假信息与网络操纵	种族和谐	宗教敏感	排外仇恨	虚假信息
ID 印度尼西亚 亚太	《电子信息和交易法》(UU ITE) · 宗教亵渎法	SARA 原则 (部落/宗教/种族/群体) · 亵渎与反伊斯兰内容 · 分裂主义	SARA 违规	宗教亵渎	族群仇恨	分裂主义
SA 沙特阿拉伯 中东	《反网络犯罪法》 · 《出版法》 · 《视听媒体法》	亵渎神明与反伊斯兰教法内容 · 道德与风纪违规 · 政治异见与反王室言论	亵渎神明	反伊斯兰教法	道德风纪	反王室
AE 阿联酋 中东	《网络犯罪法》(Federal Decree-Law No.34) · 《媒体监管法》	宗教尊重与多元文化共存 · 政治敏感与区域稳定 · 外籍人口内容合规	宗教尊重	政治稳定	文化多元	网络犯罪
TR 土耳其 中东/欧洲	TCK 299/301 · 《互联网法》第5651号 · RTÜK 广播法	侮辱国家/国父 (Atatürk) · 分裂主义与恐怖组织宣传 · 库尔德相关内容	侮辱国家元首	分裂主义	恐怖宣传	民族冲突
ZA 南非 非洲	《防止和打击仇恨犯罪与仇恨言论法案》 · 《电影与出版法》	严重种族歧视与种族隔离遗留 · 排外攻击 (Xenophobia) · 暴力与犯罪内容	种族歧视	排外攻击	暴力内容	仇恨言论
MX 墨西哥 拉美	《电信与广播法》(Ley Federal de Telecomunicaciones) · 《数字版权法》	毒品暴力与有组织犯罪内容 · 政治选举虚假信息 · 宗教与天主教敏感	毒品暴力	有组织犯罪	虚假信息	宗教敏感
BR 巴西 拉美	《互联网民权框架》(Marco Civil da Internet) · 《选举法》 · ECA 儿童保护法	政治极端化与选举虚假信息 · 结构性种族主义 · 暴力与儿童保护	政治极端	种族主义	选举虚假	儿童保护

公开数据集收集

从 HuggingFace 等平台系统性收集 8 国 68+ 个公开数据集，覆盖仇恨言论、攻击性语言、有害内容等维度，总计 ~576K 条标注样本

576K

标注数据总量

68+

公开数据集

各国公开数据集分布

SG	新加坡	×8		95,535	
TR	土耳其	×4		90,926	
ZA	南非	×16		87,946	16 种语言
ID	印度尼西亚	×14		84,318	
BR	巴西	×3		80,838	
SA	沙特阿拉伯	×9		72,936	
MX	墨西哥	×3		53,965	
TH	泰国	×2		9,516	

核心公开数据集 (按类别)

仇恨言论

- HateBR
- L-HSAB
- HateThaiSent
- HateXplain
- AfriHate (15语)

攻击性语言

- OLID-BR
- OffenseEval-AR
- IndoToxic2024
- Turkish_Offensive

有害内容综合

- Multilingual_TOXIC
- Jigsaw Toxic
- Davidson Hate
- Indonesia_7cat

多语言基准

- RabakBench (4语)
- IndoNLU
- SEAHateCheck
- Multi3Hate

输出交付物

- all_countries_binary.csv — 二分类 (违规/合规)，8 国合并
- all_countries_coarse.csv — 粗粒度多分类 (8 大类)
- all_countries_fine.csv — 细粒度多分类 (22 细类)
- all_countries_binary_dedup.csv — 去重后二分类
- 各国独有违规分类标签体系 + Cat.md

标签体系

- binary (违规/合规)
- coarse (8 大类)
- fine (22 细类)
- LLM 标注 7 类
- 5 模型交叉验证


网络数据采集与智能标注

自主爬取 9 国主流论坛内容，总计 3,743,222 条原始数据 · 507,553 条清洗后样本 · 1,300+ 陪审团标注结果



网络数据采集与智能标注

自主爬取 11 国主流论坛内容，总计 3,743,222 条原始数据 · 573,112 条清洗后样本 · 1,300+ 陪审团标注结果



Juror A

本地轻量专才

7 个 BERT 变体 · 本地 GPU 推理 · 零成本

离线

Juror B

开源中坚力量

DeepSeek · Llama · Qwen · SEA-LION

API

Juror C

云端高阶模型

Gemini 2.5 Flash · Claude 3.5 · GPT-4o-mini

API

敏感词库建设

双轨收集策略：公开关键词数据集 + 标注过程实时提取，已积累 26 万+ 条多语种敏感词/词组，覆盖 9 国

110,847

已标注关键词组

150K+

备选关键词库

8

国家覆盖

87%

词组占比



来源一

公开关键词数据集



HuggingFace · GitHub · 学术论文等多渠道检索收集



覆盖阿拉伯语、土耳其语、印尼语、泰语等 9 国主要语言及方言变体



去重合并 → 语种检测 → Google Translate 英译对齐



标签体系映射 (三层分类) → 统一入库



来源二

标注过程实时提取



Juror B/C 推理输出 → 正则+规则解析候选敏感词



语种标注 + 上下文关联 + 人工复核去噪



复核通过后补充入库，持续扩充备选词库



已累计 15 万+ 备选词，随标注量持续迭代增长

各国关键词分布与示例


SA	沙特	30,770	يا كافر سب الدين - 异教徒 / 辱骂宗教	亵渎神明 · 反伊斯兰教法
ZA	南非	23,410	kaffir voetsek - 种族辱骂 / 滚开	严重种族歧视 · 排外攻击
MX	墨西哥	17,646	plomo o plata - 吃子弹还是拿钱	毒品暴力威胁 · 有组织犯罪
ID	印尼	14,249	Cina pelit babi - 辱华 / 猪 (禁忌动物)	SARA 种族宗教违规 · 族群仇恨
BR	巴西	7,964	macaco preto favelado - 黑猴子 / 贫民窟 (种族辱骂)	结构性种族主义 · 阶级歧视
TR	土耳其	7,914	vatan haini terorist - 卖国贼 / 恐怖分子	侮辱国家民族 · 分裂主义
SG	新加坡	5,651	balik kampung Cina babi - 滚回老家 / 辱华	种族宗教和谐 · 排外仇恨
TH	泰国	3,243	สถาบันกษัตริย์ - 王室 / 叛乱 (影射王室)	冒犯君主罪 · 政治颠覆

sensitive_words_labeled.csv (110,847 行) · 单字 13,932 / 词组 96,915

多语言模型调研 — 三类方案能力对比


调研 16 编码器 + 12 护栏 + 5 开箱即用，按类别选取代表模型，6 维度雷达图叠加对比

 **编码器底座**
需微调后使用 · CPU 可用




● mDeBERTa-v3-small ● XLM-R-base ● ModernBERT-base ● SEA-LION-7B
● mBERT

 **生成式护栏**
Prompt 即用 · 可输出理由



● ShieldGemma-2B ● Llama Guard 3-8B ● Qwen2.5-0.5B ● Aya-23-8B
● ShieldGemma-9B

 **开箱即用分类器**
下载即用 · 零标注成本



● unitary/toxic-xlm ● LionGuard ● HateXplain ● NSFW-classifier




选型结论：主力引擎选用 **mDeBERTa-v3 + 各国 LoRA** 微调，利用收集的 9 国数据集训练多语言分类能力，第一层快速过滤 70–80% 合规内容；BERT 置信度不足的样本路由至 **ShieldGemma-2B / LLM** 深度推理，兼顾效率与精度，以最小成本实现多国覆盖。

多语言模型调研 — 三类方案能力对比

调研 16 编码器 + 12 护栏 + 5 开箱即用，按类别选取代表模型，6 维度雷达图叠加对比

编码器底座


需微调后使用 · CPU 可用



基于 BERT/RoBERTa/DeBERTa · 参数量 110M–3.5B
✓ 速度快 · 资源低 · 离线可用 · LoRA 微调灵活 · 社区生态丰富
✗ 需标注数据 · 各国独立微调 · 对俚语理解不如本土 BERT

生成式护栏


Prompt 即用 · 可输出理由



基于 Gemma/Llama/Qwen/Aya · 参数量 0.5B–9B
✓ 开箱即用 · 精度高 (召回率 92–93%) · 可解释 · Prompt 定制灵活
✗ 推理速度慢 (~0.3s/条) · 内存占用高 (3–8GB) · 非英语地区能力下降

开箱即用分类器

下载即用 · 零标注成本



基于 XLM-R/BERT 微调成品 · 参数量 110M–278M
✓ 最快上线 · 毫秒级推理 · ONNX <200MB · 零标注成本
✗ 通用安全标准 · 隐晦黑话漏判率高 · 无法定制合规标准



选型结论：主力引擎选用 **mDeBERTa-v3 + 各国 LoRA** 微调，利用收集的 9 国数据集训练多语言分类能力，第一层快速过滤 70–80% 合规内容；BERT 置信度不足的样本路由至 **ShieldGemma-2B / LLM** 深度推理，兼顾效率与精度，以最小成本实现多国覆盖。

各国语种模型调研详情

系统性调研编码器、生成式与开箱即用三类模型，覆盖 9 国目标语种，为微调选型提供依据

BR 巴西 拉美 推荐底座 XLM-R • mDeBERTa-v3 本土特化 HateBR (社区)	SA 沙特 中东 推荐底座 XLM-R • mDeBERTa-v3 本土特化 AraBERTv02	TH 泰国 东南亚 推荐底座 SEA-LION 300M 本土特化 WangchanBERTa	TR 土耳其 中东 推荐底座 XLM-R • mDeBERTa-v3 本土特化 BERTurk	选型结论 1 SEA-LION 是唯一针对东南亚 13 语种深度优化的模型家族，SEA-Guard 是唯一开箱即用的东南亚安全护栏 2 mDeBERTa-v3-small (141M) 同参数量下多语言 NLU 最优，CPU 即可推理 3 本土 BERT (IndoBERT/BERTurk 等) 对当地俚语黑话理解远超通用模型 4 SEAHateCheck (2026) 证实模型在隐性仇恨和俚语上普遍失败，微调是必须的
SG 新加坡 东南亚 推荐底座 SEA-LION 300M 本土特化 SEA-LION 生态	MX 墨西哥 拉美 推荐底座 XLM-R • mDeBERTa-v3 本土特化 BETO (Spanish)	ID 印尼 东南亚 推荐底座 SEA-LION 300M 本土特化 IndoBERT	ZA 南非 非洲 推荐底座 XLM-R • mDeBERTa-v3 本土特化 Afro-XLMR	东南亚 中东 拉美 非洲 选型原则：东南亚 3 国优先 SEA-LION 生态；其余 5 国通用底座 mDeBERTa + 本土 BERT 双轨并行

双路径训练策略

在调研 30+ 篇最新论文后，结合数据特点与部署需求，确定两种互补的训练范式

方案一

二分类 · 层冻结微调

核心原理

Transformer 底层学习语言通用特征（语法、构词、跨语言对齐），顶层学习任务特有模式。冻结底层 = 保留 100+ 语种的预训练知识，仅微调顶层适配二分类任务，可训练参数减少 ~65%。

- **底座：** mDeBERTa-v3 / XLM-RoBERTa — 覆盖 100+ 语种的通用多语言编码器
- **做法：** 冻结底层 8 层 Transformer，仅训练顶层 4 层 + 二分类 MLP 头 · Focal Loss ($\gamma=2$) 处理类别不平衡（违规 < 5%）
- **论文支撑：** Shirdel et al. (2026, arXiv:2601.02697) — 冻结底层可**保持甚至提升** F1 性能，训练速度提升 2.3×
- **适用场景：** 全量数据快速初筛 · 判定违规/合规 · 为多分类提供候选

mDeBERTa-v3

冻结底层 8 层

Focal Loss

参数量 -65%

可训练参数

~35%

训练加速

2.3x

推理延迟

~20ms

目标 F1

> 90%

方案二

多分类 · LoRA 微调

核心原理

LoRA 将权重更新分解为两个低秩矩阵 ($A \times B$, rank $r=16$)，注入 Attention 层，原始权重完全冻结。基于微软 mDeBERTa-v3 底座，每个国家只需训练 ~0.3% 的参数量作为轻量 Adapter，8 国 Adapter 总大小仅 ~200MB。

- **底座：** mDeBERTa-v3 (microsoft/mdeberta-v3-base) — 微软研究院多语言 BERT · 解耦注意力 + 词嵌入分解 · NLU 全面优于 mBERT
- **做法：** LoRA ($r=16$, $\alpha=32$) 注入 Q/K/V/O + 解耦注意力权重 · 每国独立 Adapter · 分类头输出通用 + 该国特有标签
- **关键优势：** 各国 Adapter 互不干扰可独立更新 · 推理时按需加载 · 一个底座服务所有国家 · 增量部署零停机
- **适用场景：** 细粒度多标签分类 · 泰国冒犯君主 / 印尼 SARA / 沙特亵渎神明 · 每国可独立扩展特有违规类别

LoRA $r=16$ $\alpha=32$

Adapter ~25MB/国

8 国独立

多标签头

可训练参数

~0.3%

每国体积

~25MB

总 Adapter

~200MB

8 国覆盖

100%

训练结果对比

基于 mBERT / XLM-R / mDeBERTa 三个底座，在 8 国数据上对比冻结与不冻结的二分类训练效果，并加入开箱即用模型作为基线

模型	方式 / 类型	数据集	Accuracy	F1	Precision	Recall	推理延迟
▸ 微调模型 (Fine-tuned)							
mDeBERTa-v3	微软						
	冻结 8 层	all_countries_binary	TBD	TBD	TBD	TBD	TBD
	不冻结	all_countries_binary	TBD	TBD	TBD	TBD	TBD
XLM-RoBERTa	Meta						
	冻结 8 层	all_countries_binary	TBD	TBD	TBD	TBD	TBD
	不冻结	all_countries_binary	TBD	TBD	TBD	TBD	TBD
mBERT	Google						
	冻结 8 层	all_countries_binary	TBD	TBD	TBD	TBD	TBD
	不冻结	all_countries_binary	TBD	TBD	TBD	TBD	TBD
▸ 开箱即用基线 (Off-the-shelf Baselines)							
unitary/toxic-xlm	开箱即用						
	—	all_countries_binary	TBD	TBD	TBD	TBD	TBD
LionGuard	东南亚专精						
	—	all_countries_binary	TBD	TBD	TBD	TBD	TBD
HateXplain	可解释						
	—	all_countries_binary	TBD	TBD	TBD	TBD	TBD

多分类结果对比

在 binary / coarse / fine 三层分类体系上对比微调模型与开箱即用基线的多分类效果

模型	分类层级	类别数	Accuracy	Macro F1	Weighted F1	Recall	推理延迟
▸ 微调模型 (Fine-tuned)							
mDeBERTa-v3	冻结 8 层						
	binary	2 类	TBD	TBD	TBD	TBD	TBD
	coarse	8 类	TBD	TBD	TBD	TBD	TBD
	fine	22 类	TBD	TBD	TBD	TBD	TBD
mDeBERTa-v3	不冻结						
	binary	2 类	TBD	TBD	TBD	TBD	TBD
	coarse	8 类	TBD	TBD	TBD	TBD	TBD
	fine	22 类	TBD	TBD	TBD	TBD	TBD
XLM-RoBERTa	冻结 8 层						
	binary	2 类	TBD	TBD	TBD	TBD	TBD
	coarse	8 类	TBD	TBD	TBD	TBD	TBD
	fine	22 类	TBD	TBD	TBD	TBD	TBD
▸ 开箱即用基线 (Off-the-shelf Baselines)							
unitary/toxic-xlm	6 维毒性分数						
	binary	2 类	TBD	TBD	TBD	TBD	TBD
	coarse	8 类	TBD	TBD	TBD	TBD	TBD
	fine	22 类	TBD	TBD	TBD	TBD	TBD
LionGuard	东南亚专精						

内容安全审核智能体

构建多智能体协作系统，通过热路径快速预筛 + 冷路径深度分析的双层架构，实现高效、精准、低成本的内容安全审核



双层流水线架构

请求抵达后先经 Gateway 热路径极速预筛，未命中则升级至 LangGraph 冷路径由 4 个 Agent 深度分析



未命中 • 升级至冷路径



Gateway 快速预筛

独立于 LangGraph 之外的热路径，6 个检查按成本升序排列，命中即返回 — 70-80% 请求在 5ms 内零成本拦截

L0a本地内存缓存<0.01ms

SHA256 文本哈希 → Python TTLCache 查询 · 10万条目 · 1h TTL

输入

打倒XXX，推翻XXX

↓ SHA256

a3f8c2d1...

↓ TTLCache 查询

违规

5 分钟前 LLM 判定 · conf=0.96 · 直接复用

L0bRedis 共享缓存~0.5ms

跨 Worker 进程共享 · 优雅降级 · 分布式一致性

输入

Seni öldüreceğim (土耳其语)

↓ Worker A 审核完成 → Redis SET

key: mod:tr:alb2...

↓ Worker C 相同文本 → Redis GET

违规

命中 Worker A 的缓存 · 跳过冷路径

L1aAC 自动机关键词~0.5ms

pyahocorasick O(n) + jieba 上下文校验 · 5 类关键词

输入

中共下台

↓ 匹配「下台」

拦截

独立违禁词 · conf=1.0

输入

操场

↓ 命中「操」

升级

嵌入式命中 · conf=0.6 → L1b

L1b白名单过滤<0.1ms

正则匹配已知误伤短语 · 关键词命中后二次校验

输入

操场上跑步的人很多，大家一起来锻炼

↓ L1a 命中「操」→ conf=0.6 → 升级

正则匹配

操场

体操

早操

放行

白名单命中 · 正常体育话题

L2ChromaDB 语义缓存~5ms

BGE-small-zh-v1.5 嵌入 · cosine ≥ 0.95 命中 · 换说法也能拦截

已缓存 · 违规

去死吧你这个蠢货

VS

新请求 · 待判定

你怎么不去死呢废物

↓ BGE 嵌入 → cosine=0.97 ≥ 0.95

违规

语义命中 · 直接复用历史判定 · 措辞不同仍能识别

L3图像哈希去重~2ms

dHash 感知哈希 · 已知有害图像指纹库 · 裁剪/缩放/压缩仍可匹配

已知有害 · 指纹库

f3a2b1c8d4e5...

→

新上传 (裁剪+滤镜)

f3a2b1c8d4e7...

↓ 汉明距离=3 < 阈值 → 匹配成功

拦截

同一有害图片 · 裁剪/缩放/滤镜均无法逃逸

<5ms

平均响应延迟

\$0

单次调用成本

70-80%

请求拦截率

越便宜的检查越靠前，逐级升级避免浪费


独立于 LangGraph，避免框架调度开销

缓存命中直接复用历史决策，无需重复推理

独立违禁词 (政治/暴力) 零容忍直接拦截

文本分析 & 图像分析

文本 Agent 三层漏斗逐级提纯 + 图像 Agent 多模态感知，冷路径核心分析引擎



决策聚合 & 数据飞轮

加权聚合多 Agent 结果 · 缓存写回形成闭环 · 离线数据飞轮驱动模型持续进化

⚖️ 决策 Agent

⚡ 加权聚合

text 40% + image 35% + multimodal 25% · 缺失维度自动归一化

🛡️ 零容忍覆写

政治 / 恐怖主义关键词命中 → 无论模型得分均强制拦截

👤 灰色地带路由

置信度 [0.3, 0.7] → 人工复核队列 · <0.3 放行避免误杀

✅ 安全优先

安全标签永不拦截 · 宁可漏过不可误杀

🔑 动作 Agent

💾 缓存写回

L0a TTLCache + L0b Redis + L1 ChromaDB 语义向量三层回写

📋 人工复核入队

review 决策 → JSONL 队列 → 人工标注 → 回流训练集

📊 事件记录

全链路 trace 追加式写入 JSONL 事件存储 · 离线分析使用

🔄 离线数据飞轮 · 五步闭环

1



事件采集

全链路 trace → 追加式 JSONL 事件存储

2



数据集构建

银标 (模型集成) + 金标 (人工复核) · 误伤模式分析

3



微调触发

标注量 > 5000 → 自动触发 LoRA 微调 (peft + BERT)

4



漂移检测

7d vs 30d 准确率对比 · 阈值自动校准

5



模型升级

LoRA 合并 → ONNX 导出 → 替换线上 BERT → 关闭 LLM

工作输出总览

试用期内围绕两大工作方向，形成以下核心交付物



小语种内容安全能力储备

覆盖 5 大区域 · 8 个国家 · 10+ 语种



8 国覆盖 AI 法案 审核法律 分类标签

各国法律法规

新加坡/泰国/沙特/土耳其/印尼/巴西/墨西哥/南非 · AI 监管法规 + 内容审核法律要求 + 文化敏感点梳理 · 各国特有违规分类标签体系



宗教敏感 政治红线 风俗禁忌

价值观与文化禁忌

伊斯兰/佛教/天主教等宗教敏感领域分析 · 种族和谐/冒犯君主/分裂主义等政治红线 · 风俗禁忌与社交礼仪边界



公开 30+ 377K 标注 爬取 374万 清洗 45万 3 份 CSV

数据集收集

公开：HuggingFace 收集仇恨言论/攻击性语言/有害内容/多语言基准 4 大类 · 爬取：自主爬取 8 国主流论坛 · 457,706 条清洗后样本 · 统一合并 binary/coarse/fine



110,847 条 150K+ 备选 8 国标签 双轨收集

关键词库建设

公开关键词数据集 + Juror B/C 推理实时提取 · 单字 13,932 / 词组 96,915 · 各国独有违规标签 (SARA/冒犯君主等) · sensitive_words_labeled.csv



30+ 论文 16 编码器 12 护栏 双路径 8 国 Adapter

模型调研与训练

XLNet / mDeBERTa / SEA-LION / 本土 BERT 全面调研 · 方案一：冻结底层 8 层 + Focal Loss · 方案二：LoRA r=16 $\alpha=32$ ~25MB/国 · 8 国独立训练



内容审核智能体 POC

Multi-Agent Content Moderation System

- FastAPI + LangGraph 双层架构
- 热路径 6 层预筛 + 冷路径 4 Agent DAG
- 文本三层漏斗 + 图像四步处理
- 离线数据飞轮 + 评估基准体系
- 源码 + 架构文档 + 部署指南



AI Agent 安全洞察

AI Agent Security Insights

- AI Agent 安全风险全景分析
- 提示注入/工具滥用/数据泄露等威胁建模
- 安全防护策略与最佳实践建议
- 胶片 presentation 形式交付



Agent 安全技术文档

Agent Security Technical Documentation

- Agent 安全架构设计文档
- 安全审计与评估方法论
- 防护机制实现细节与测试报告
- 后续安全运营与迭代规划

试用期总结与思考

工作成果回顾、经验沉淀与个人成长反思

03

小语种审核能力建设路径

- ▶ 语种调研：评估目标市场语言分布、文化特性与内容风险画像
- ▶ 人才储备：建立小语种审核人才招聘、培训与考核体系
- ▶ 标准建设：制定多语种内容安全审核标准与操作规范
- ▶ 工具平台：搭建适配小语种的内容审核工具与自动化 pipeline
- ▶ 质量管控：建立多语种审核质量抽检与持续优化机制

下一步工作目标与计划

未来工作方向、阶段目标与实施路径规划

04

新市场覆盖 & 模型深化

在现有 8 国基础上向更多出海目标国家扩展，同时探索小语种大语言模型的可行性与必要性



新出海国家能力扩展

AE 阿联酋 · 中东第二站

沙特经验复用 → 构建阿联酋阿拉伯语数据集 · 适配 UAE 互联网内容法规 · 阿联酋本土敏感词库建设

VN 越南 · 东南亚第四国

调研越南《网络安全法》与内容审查要求 · 爬取越南主流论坛数据 · 适配 ViBERT 本土模型

PH 菲律宾 · 英语 + 他加禄语

他加禄语 (Tagalog) 仇恨言论数据集收集 · 菲律宾特有文化与宗教禁忌分析 · 双语言 (EN+TL) 审核方案

EG 埃及 · 北非门户

埃及阿拉伯语方言敏感词库 · 调研埃及内容审查法律 · 北非阿拉伯语数据收集与模型适配

复制策略: 将 8 国已验证的数据采集→标注→训练 SOP 快速复制到新市场，每国周期预计缩短至 2-3 周



小语种大模型能力评估

当前 POC 依赖 BERT 编码器 + 通用 LLM (DeepSeek/GPT) 的组合方案。需要评估以下小语种大语言模型在内容安全审核任务上的表现，判断是否需要针对特定语种进行大语言模型的继续训练 (Continue Pre-training) 或指令微调 (SFT):

SEA-LION 7B

东南亚 13 语种

唯一东南亚系 LLM · 需评估 Thai/Indo/Bahasa 内容安全能力

JAIS 13B

阿拉伯语 + 英语

中东首个开源双语 LLM · 沙特/阿联酋/埃及适配测试

Türk LLM 7B

土耳其语

土耳其本土 LLM · 评估对侮辱国家/分裂主义的判定精度

Qwen2.5 系列

多语言 (含阿/泰/越)

阿里通义千问 · 重点测试东南亚与中东语种的安全对齐能力

Aya-23

23 语种

Cohere For AI 多语言模型 · 覆盖非洲语言 · 评估低资源语种表现

评估基准: SEAHateCheck + 自建 8 国测试集

决策输出: 继续训练 vs 仅用 BERT + API LLM

账号风控智能体 & 整体路线图

将内容安全多 Agent 协作经验迁移至账号风控场景，建立跨领域统一智能审核体系

账号风控智能体

基于内容审核 Multi-Agent POC 积累的架构经验 (热路径 + 冷路径 + 离线飞轮)，将多 Agent 协作模式迁移至账号风控场景，构建统一的安全智能审核体系。

风险信号聚合

聚合账号行为、设备指纹、登录轨迹、社交图谱等多维信号，构建用户风险画像

行为序列

设备指纹

社交图谱

内容-账号联合建模

将内容审核 Agent 的输出 (违规历史) 作为账号风控的特征输入，实现端到端的用户-内容联合风险评估

特征融合

联合推理

历史追溯

实时决策引擎

复用 Gateway 热路径架构 → 规则引擎 + 缓存层 → 毫秒级账号风险判定 → 高置信拦截 + 灰区人工复核

实时判定

规则引擎

灰色地带

离线分析与模型迭代

复用数据飞轮架构 → 账号标注数据回流 → 图神经网络/序列模型训练 → 模型持续升级

GNN

序列模型

数据飞轮

阶段路线图

Phase 1 2026 Q2-Q3

- 8 国 LoRA Adapter 训练完成并部署上线
- 中文 BERT 替换，降低 LLM 调用成本
- 阿联酋 + 越南 2 个新国家数据收集启动
- SEA-LION 7B 内容安全能力基准评估完成

Phase 2 2026 Q3-Q4

- 新国家 (阿联酋/越南/菲律宾) 模型落地
- 小语种 LLM 是否继续训练的决策 & 实验方案
- 账号风控智能体 POC 架构设计与原型开发
- 本地 LLM (SGLang) 全量替换 API 调用

Phase 3 2026 Q4 - 2027 Q1

- 内容 + 账号统一安全智能体平台
- 数据飞轮全自动化 (采集→训练→部署)
- 覆盖 12+ 国家 · 15+ 语种 · 双领域
- 形成可对外输出的标准化安全能力产品

试用期回顾与心得

在技术积累之外，对工作方法 with 成长方向的思考同样重要

技术学习总结

-  **内容安全**
8 国法规、22 标签三层分类体系、完整 pipeline
-  **NLP**
48+ 模型调研、LoRA 微调、30+ 篇论文跟进
-  **Agent 工程**
LangGraph 编排、6 种 LLM 后端、离线飞轮
-  **工程实践**
6 大独立系统从零开发交付

► 展望

完成 8 国模型 LoRA 微调与部署，启动数据飞轮；引入多语言 BERT 压缩 LLM 调用率至 5--10\%；部署本地 LLM 实现离线自持，持续深化 Agent 安全与多语言 NLP 能力。

不积跬步，无以至千里

面对小语种内容安全这一从零起步的复杂课题

- 1 按不同粒度分解任务，制定阶段性目标**
调研 → 数据 → 模型 → 工程四阶段逐层拆解，里程碑驱动，避免面对宏大目标时的无从下手。
- 2 按时总结，保证工作进度可控可跟踪**
6 个阶段性项目持续输出文档，沉淀知识资产，工作进度可视化、可追溯。

不足与改进

- 1 放开心态，大胆讨论大胆做**
前期倾向「先研究透彻再拿出来」，探索性工作中早暴露想法、主动寻求反馈效率更高。未来将更主动发起技术讨论，在交流中加速迭代。
- 2 知识面不够宽，后续需加快学习速度**
小语种 NLP 与 Agent 安全领域积累仍需加强，后续通过论文精读 + 代码复现 + 内部分享加速知识积累。

感谢聆听

期待各位专家的指导与建议