

PROBATION DEFENSE

转正答辩

SOC 内容安全审核 · 小语种能力储备

内容安全运营中心

2026 年度转正答辩

目录

01 自我介绍

个人背景、教育经历与工作信息概览

02 主要工作内容及输出

全球多地区小语种内容安全能力储备与核心成果

03 试用期总结与思考

工作成果回顾、经验沉淀与个人成长反思

04 下一步工作目标与计划

未来工作方向、阶段目标与实施路径

自我介绍

个人背景与工作经历概览

01

个人信息



请补充姓名

部门 请补充 项目组 请补充 入职时间 请补充



毕业院校

请补充



研究方向

请补充



导师

请补充



直接主管

请补充

博士期间论文发表

[1] 请补充论文标题
期刊 / 会议名称, 年份

[2] 请补充论文标题
期刊 / 会议名称, 年份

[3] 请补充论文标题
期刊 / 会议名称, 年份

[4] 请补充论文标题
期刊 / 会议名称, 年份

主要工作内容及输出

全球多地区小语种内容安全能力储备与核心工作成果

02

主要工作内容

两大核心工作方向



小语种内容安全 审核能力储备

覆盖 5 大区域、8+ 个国家，构建多语种内容安全审核标准、人才体系与工具平台，实现从 0 到 1 的小语种审核能力落地。

- 语种调研
- 人才储备
- 标准建设
- 质量管控



内容安全审核 智能体的探索

探索 AI 智能体在内容安全审核场景中的应用，提升审核效率与准确性，降低人工成本，构建智能化审核能力。

- 智能审核
- 自动化 Pipeline
- 人机协同
- 效率提升

Token 出海与内容安全

Token 正积极推进全球化战略，目前已覆盖 **请补充国家/地区** 等市场。

随着海外用户规模持续增长，平台内容呈现多语种、多文化、多地域的复杂特征，对内容安全审核能力提出了更高的要求。

小语种内容审核面临**人才稀缺**、**标准缺失**、**工具不足**三大核心挑战，构建体系化的小语种内容安全能力成为保障出海业务合规运营的关键课题。

亚太

中东

欧洲

非洲

南美



IMAGE

Token 出海市场分布图 / 全球业务覆盖地图

720 x 540

小语种内容安全能力储备的战略价值



保障出海业务合规

建立多语种审核标准，满足各地区法律法规与内容监管要求，降低合规风险



支撑全球化用户体验

积累小语种内容理解能力，确保跨地区内容安全策略的一致性与本地化平衡



构建可复用的能力体系

形成标准化的语种能力建设方法论，加速新市场覆盖，降低边际成本



提升组织核心竞争力

打造差异化的小语种内容安全壁垒，增强团队国际化运营能力与行业影响力

全球覆盖

小语种覆盖国家与地区概览

覆盖 5 大区域、8 个重点国家，构建多语种内容安全能力矩阵

亚太

APAC

3 个国家

TH 泰国 泰语

佛教文化主导，王室相关内容审查极为严格

SG 新加坡 英 / 马 / 中 / 泰米尔

多元种族社会，种族与宗教议题高度敏感

ID 印度尼西亚 印尼语

全球最大穆斯林人口国，宗教审查要求极高

中东与欧洲

ME • EU

3 个国家

SA 沙特阿拉伯 阿拉伯语

严格教法国家，文化禁忌繁多，内容管控严苛

AE 阿联酋 阿拉伯语

中东互联网枢纽，多元外籍人口，内容合规要求严格

TR 土耳其 土耳其语

世俗化穆斯林国家，政治与民族问题敏感度高

非洲与南美

AF • LATAM

3 个国家

ZA 南非 英 / 南非语 / 祖鲁语等

多种族多语言社会，种族遗留与暴力内容突出

MX 墨西哥 西班牙语

天主教文化为主，毒品与暴力内容是审核重点

BR 巴西 葡萄牙语

多民族融合，暴力内容与虚假信息问题显著

⚠ 主要挑战

人才稀缺 小语种审核人员招募困难

标准缺失 多语种审核标准从零建立

文化壁垒 本地文化理解门槛高

工具不足 小语种 NLP 能力薄弱

各国法规政策与风俗调研

在构建小语种内容审核能力之前，首先深入了解各国风俗习惯、法律法规与 AI 监管政策，明确内容审核的合规边界

调研维度



AI 法规与监管

各国人工智能法案、数据保护条例、平台内容责任法规



内容审核法律

仇恨言论、暴力内容、色情内容等各维度的法律界定



宗教与文化禁忌

伊斯兰教法、王室保护、种族和谐等敏感领域



语言与俚语特性

当地方言、网络黑话、隐晦表达的文化含义

工作输出

输出各国内容合规调研报告，涵盖 AI 法规、内容审核法律要求及文化敏感点，形成分类标签体系

SG 新加坡

法规：《网络安全法》《维护种族和谐法》

审核重点：种族/宗教和谐、CMIO 框架攻击

SA 沙特阿拉伯

法规：《反网络犯罪法》《出版法》

审核重点：亵渎神明、反伊斯兰内容、道德风纪

ID 印度尼西亚

法规：《电子信息和交易法》(UU ITE)

审核重点：SARA 原则 (部落/宗教/种族/群体)

TH 泰国

法规：《刑法》第112条、《计算机犯罪法》

审核重点：冒犯君主罪 (Lèse-majesté)、政治煽动

TR 土耳其

法规：TCK 299/301、《互联网法》第5651号

审核重点：侮辱国家/国父、分裂主义与恐怖组织

BR 巴西

法规：《互联网民权框架》(Marco Civil)

审核重点：政治极端化、结构性种族主义

公开数据集收集


从 HuggingFace 等平台系统性收集 8 个目标国家的内容安全相关公开数据集，覆盖仇恨言论、攻击性语言、有害内容等维度

377K+

标注数据总量

30+

数据集数量



核心数据集 (按类别)

仇恨言论检测

HateBR BR · Arabic_Hate_Speech SA · turkish-hate-speech TR · HateThaiSent TH

攻击性语言

olid-br BR · turkish-offensive TR · id-abusive ID

有害内容综合

harmful-text BR · hate-speech-superset 系列 

多语言基准


RabakBench SG(4语) · AfriHate ZA(15语) · IndoNLU ID

输出交付物

- 统一合并数据集: **all_countries_binary.csv** (二分类, 377K 条)
- 统一合并数据集: **all_countries_coarse.csv** (五分类, 377K 条)
- 统一合并数据集: **all_countries_fine.csv** (细粒度, 377K 条)
- 各国独有违规分类标签体系 (Cat.md)

网络数据采集与智能标注

自主爬取 8 国主流论坛内容，总计 3,743,222 条原始数据 · 457,706 条清洗后样本 · 1,300+ 陪审团标注结果



Juror A

本地轻量专才

7 个 BERT 变体 · 本地 GPU 推理 · 零成本

离线

Juror B

开源中坚力量

DeepSeek · Llama · Qwen · SEA-LION

API

Juror C

云端高阶模型

Gemini 2.5 Flash · Claude 3.5 · GPT-4o-mini

API

敏感词库建设

双轨收集策略：公开关键词数据集 + 标注过程实时提取，已积累 26 万+ 条多语种敏感词/词组

110,847

已标注关键词组

150K+

备选关键词库

8

国家覆盖

87%

词组占比

来源一

公开关键词数据集

从 HuggingFace、GitHub、学术论文等渠道系统性收集各语种敏感词/仇恨言论词典，经去重、翻译、归类后统一入库。

HuggingFace

GitHub 开源

学术论文

来源二

标注过程实时提取

陪审团标注时，Juror B/C 推理过程中识别到的敏感词/词组自动抽取，经人工复核后补充入库，持续扩充 15 万+ 备选词库。

Juror B 推理

Juror C 推理

人工复核

各国关键词分布 & 示例

SA	SA	沙特	30,770	أنجس&تفوا — 肮脏&呸	亵渎反伊斯兰 · 不道德与 LGBTQ
ZA	ZA	南非	23,410	3afrita&7mara — 恶魔和驴	严重种族主义 · 排外主义
MX	MX	墨西哥	17,646	#noespáisparamujeres — 暗示不适合女性的国家	性别暴力 · 毒品文化
ID	ID	印尼	14,249	#নীচ — 低贱、卑鄙	SARA 违规
BR	BR	巴西	7,964	04&transão — 对跨性别者的侮辱性称呼	结构性种族主义 · 色情俚语
TR	TR	土耳其	7,914	3&gunde&sevgili°istirmek — 每三天换一个男朋友	侮辱国家 · 分离主义恐怖
SG	SG	新加坡	5,651	-1m69&boires&à&la&fontaine — 嘲笑女性身高贬低外貌	种族宗教和谐 · Singlish 粗俗语
TH	TH	泰国	3,243	เอาจ — 泰语粗口，侮辱他人	冒犯君主 · 政治煽动

sensitive_words_labeled.csv (110,847 行) · 单字 13,932 / 词组 96,915 · 右侧为各国特有违规标签类别

各国语种模型调研

系统性调研编码器、生成式与开箱即用三类模型，覆盖 8 国目标语种，为微调选型提供依据

16

编码器底座

XLM-R · mDeBERTa · ModernBERT

12

生成式护栏

SEA-Guard · ShieldGemma · Qwen

5

开箱即用

multilingual-toxic · SEA-Guard

8/8

目标国家全覆盖

每国均有编码器+本土方案

BR 巴西

拉美

推荐底座

XLM-R · mDeBERTa-v3

本土特化

HateBR (社区)

SA 沙特

中东

推荐底座

XLM-R · mDeBERTa-v3

本土特化

AraBERTv02

TH 泰国

东南亚

推荐底座

SEA-LION 300M

本土特化

WangchanBERTa

TR 土耳其

中东

推荐底座

XLM-R · mDeBERTa-v3

本土特化

BERTurk

SG 新加坡

东南亚

推荐底座

SEA-LION 300M

本土特化

SEA-LION 生态

MX 墨西哥

拉美

推荐底座

XLM-R · mDeBERTa-v3

本土特化

BETO (Spanish)

ID 印尼

东南亚

推荐底座

SEA-LION 300M

本土特化

IndoBERT

ZA 南非

非洲

推荐底座

XLM-R · mDeBERTa-v3

本土特化

Afro-XLMR

核心发现

1 SEA-LION 是唯一针对东南亚 13 语种深度优化的模型家族，SEA-Guard 是唯一开箱即用的东南亚安全护栏

2 mDeBERTa-v3-small (141M) 同参数量下多语言 NLU 最优，CPU 即可推理

3 本土 BERT (IndoBERT/BERTurk 等) 对当地俚语黑话理解远超通用模型

4 SEAHateCheck (2026) 证实模型在隐性仇恨和俚语上普遍失败，微调是必须的

东南亚 中东 拉美 非洲

选型原则：东南亚 3 国优先 SEA-LION 生态；其余 5 国通用底座 mDeBERTa + 本土 BERT 双轨并行

双路径训练策略

在调研 30+ 篇最新论文后，结合数据特点与部署需求，确定两种互补的训练范式

方案一

二分类 · 层冻结微调

核心原理

Transformer 底层学习语言通用特征（语法、构词、跨语言对齐），顶层学习任务特有模式。冻结底层 = 保留 100+ 语种的预训练知识，仅微调顶层适配二分类任务，可训练参数减少 ~65%。

- 底座：**mDeBERTa-v3 / XLM-RoBERTa — 覆盖 100+ 语种的通用多语言编码器
- 做法：**冻结底层 8 层 Transformer，仅训练顶层 4 层 + 二分类 MLP 头；使用 **Focal Loss** ($\gamma=2$) 处理严重类别不平衡（违规样本 < 5%）
- 论文支撑：**Shirdel et al. (2026, arXiv:2601.02697) 在 mBERT/XLM-R 多语言仇恨言论检测上证明冻结底层可**保持甚至提升** F1 性能，训练速度提升 2.3×
- 适用场景：**全量数据快速初筛，判定"违规/合规"，为后续细粒度多分类提供候选

mDeBERTa-v3

冻结底层 8 层

Focal Loss

参数量 -65%

方案二

多分类 · LoRA 微调

核心原理

LoRA 将权重更新分解为两个低秩矩阵 ($A \times B$, rank $r=16$)，注入 Attention 层，原始权重完全冻结。基于微软 mDeBERTa-v3 底座，每个国家只需训练 ~0.3% 的参数量作为轻量 Adapter，8 国 Adapter 总大小仅 ~200MB。

- 底座：**mDeBERTa-v3 (microsoft/mdeberta-v3-base) — 微软研究院多语言 BERT，覆盖 100+ 语种，解耦注意力 + 词嵌入分解，多语言 NLU 全面优于 mBERT
- 做法：**LoRA ($r=16$, $\alpha=32$) 注入 Attention 矩阵 (Q/K/V/O) + 解耦注意力权重，每个国家独立训练一个 Adapter；分类头同时输出通用标签 + 该国特有标签
- 关键优势：**各国 Adapter 互不干扰，可独立更新；推理时按需加载对应国家 Adapter，一个底座服务所有国家
- 适用场景：**细粒度多标签分类 — 泰国额外判定冒犯君主 (Lèse-majesté)，印尼判定 SARA 违规，沙特判定亵渎神明

LoRA $r=16$ $\alpha=32$

Adapter ~25MB/国

8 国独立

多标签头

训练结果对比

两种方案在各国数据集上的性能对比，以及与大模型基线的横向评估

二分类 Accuracy

方案一

待补充

二分类 F1

方案一

待补充

多分类 Macro-F1

方案二

待补充

推理延迟 (ms)

方案一

待补充

方案二

待补充

模型体积 (MB)

方案一

待补充

方案二

待补充

可训练参数占比

方案一

~35%

方案二

~0.3%

与大模型基线对比

基线模型	参数量	推理模式	多语言支持	各国特有标签
unitary-toxic	~110M	本地 GPU	有限 (英文为主)	不支持
ShieldGemma	2B / 9B	本地 GPU	英文为主	不支持
Llama Guard 3	8B	本地 GPU	一般	不支持
GPT-4o-mini	~8B (推测)	云端 API	优秀 (100+ 语种)	需 prompt 引导



核心参考文献: [mDeBERTa-v3 \(Microsoft, 2023\)](#) — 解耦注意力多语言编码器 · [Layer Freezing \(arXiv:2601.02697\)](#) — 冻结层策略实证 · [SEA-Guard \(arXiv:2602.01618\)](#) — 东南亚安全对齐 · [SEAHateCheck \(arXiv:2603.16070\)](#) — 基准评估 · 共调研 30+ 篇论文后确定上述两种训练范式

内容安全审核智能体

构建多智能体协作系统，通过热路径快速预筛 + 冷路径深度分析的双层架构，实现高效、精准、低成本的内容安全审核



双层流水线架构

请求抵达后先经 Gateway 热路径极速预筛，未命中则升级至 LangGraph 冷路径由 4 个 Agent 深度分析



Gateway 快速预筛

独立于 LangGraph 之外的热路径，6 个检查按成本升序排列，命中即返回 — 70-80% 请求在 5ms 内零成本拦截

L0a本地内存缓存<0.01ms

SHA256 文本哈希 → Python TTLCache 查询 · 10万条目 · 1h TTL

输入

打倒XXX，推翻XXX

↓ SHA256

a3f8c2d1...

↓ TTLCache 查询

违规

5 分钟前 LLM 判定 · conf=0.96 · 直接复用

L0bRedis 共享缓存~0.5ms

跨 Worker 进程共享 · 优雅降级 · 分布式一致性

输入

Seni öldüreceğim (土耳其语)

↓ Worker A 审核完成 → Redis SET

key: mod:tr:a1b2...

↓ Worker C 相同文本 → Redis GET

违规

命中 Worker A 的缓存 · 跳过冷路径

L1aAC 自动机关键词~0.5ms

pyahocorasick O(n) + jieba 上下文校验 · 5 类关键词

输入

中共下台

↓ 匹配「下台」

拦截

独立违禁词 · conf=1.0

输入

操场

↓ 命中「操」

升级

嵌入式命中 · conf=0.6 → L1b

L1b白名单过滤<0.1ms

正则匹配已知误伤短语 · 关键词命中后二次校验

输入

操场上跑步的人很多，大家一起来锻炼

↓ L1a 命中「操」→ conf=0.6 → 升级

正则匹配

操场

体操

早操

放行

白名单命中 · 正常体育话题

L2ChromaDB 语义缓存~5ms

BGE-small-zh-v1.5 嵌入 · cosine ≥ 0.95 命中 · 换说法也能拦截

已缓存 · 违规

去死吧你这个蠢货

VS

新请求 · 待判定

你怎么不去死呢废物

↓ BGE 嵌入 → cosine=0.97 ≥ 0.95

违规

语义命中 · 直接复用历史判定 · 措辞不同仍能识别

L3图像哈希去重~2ms

dHash 感知哈希 · 已知有害图像指纹库 · 裁剪/缩放/压缩仍可匹配

已知有害 · 指纹库

f3a2b1c8d4e5...

→

新上传 (裁剪+滤镜)

f3a2b1c8d4e7...

↓ 汉明距离=3 < 阈值 → 匹配成功

拦截

同一有害图片 · 裁剪/缩放/滤镜均无法逃逸

<5ms

平均响应延迟

\$0

单次调用成本

70-80%

请求拦截率

越便宜的检查越靠前，逐级升级避免浪费


独立于 LangGraph，避免框架调度开销

缓存命中直接复用历史决策，无需重复推理

独立违禁词 (政治/暴力) 零容忍直接拦截

文本分析 & 图像分析

文本 Agent 三层漏斗逐级提纯 + 图像 Agent 多模态感知，冷路径核心分析引擎



决策聚合 & 数据飞轮

加权聚合多 Agent 结果 · 缓存写回形成闭环 · 离线数据飞轮驱动模型持续进化

⚖️ 决策 Agent

⚡ 加权聚合

text 40% + image 35% + multimodal 25% · 缺失维度自动归一化

🛡️ 零容忍覆写

政治 / 恐怖主义关键词命中 → 无论模型得分均强制拦截

👤 灰色地带路由

置信度 [0.3, 0.7] → 人工复核队列 · <0.3 放行避免误杀

✅ 安全优先

安全标签永不拦截 · 宁可漏过不可误杀

🔑 动作 Agent

📁 缓存写回

L0a TTLCache + L0b Redis + L1 ChromaDB 语义向量三层回写

📋 人工复核入队

review 决策 → JSONL 队列 → 人工标注 → 回流训练集

📊 事件记录

全链路 trace 追加式写入 JSONL 事件存储 · 离线分析使用

🔄 离线数据飞轮 · 五步闭环

1



事件采集

全链路 trace → 追加式 JSONL 事件存储

2



数据集构建

银标 (模型集成) + 金标 (人工复核) · 误伤模式分析

3



微调触发

标注量 > 5000 → 自动触发 LoRA 微调 (peft + BERT)

4



漂移检测

7d vs 30d 准确率对比 · 阈值自动校准

5



模型升级

LoRA 合并 → ONNX 导出 → 替换线上 BERT → 关闭 LLM

📊 评估基准

数据集

toxic-chat

lmsys/toxic-chat

数据集

Aegis-AI

NVIDIA Content Safety v2.0

数据集

hate_speech

目标

F1 > 90%

🎯 已知提升方向

CN 中文 BERT 替换 — 当前英文 BERT 无法评估中文，导致中文全走 L3 (高成本)

🌐 多语言 8 国 BERT 微调 — 针对目标国家语种微调专属分类模型

⚡ ONNX 全量加速 — 替换 HuggingFace pipeline，推理速度提升 2-3×

💰 本地 LLM 取代 API — SGLang 部署 Qwen2.5，消除 API 调用成本

工作输出总览

试用期内围绕两大工作方向，形成以下核心交付物



小语种内容安全能力储备

覆盖 5 大区域 · 8 个国家 · 10+ 语种



8 国覆盖

AI 法案

审核法律

分类标签

各国法律法规

新加坡/泰国/沙特/土耳其/印尼/巴西/墨西哥/南非 · AI 监管法规 + 内容审核法律要求 + 文化敏感点梳理 · 各国特有违规分类标签体系



宗教敏感

政治红线

风俗禁忌

价值观与文化禁忌

伊斯兰/佛教/天主教等宗教敏感领域分析 · 种族和谐/冒犯君主/分裂主义等政治红线 · 风俗禁忌与社交礼仪边界



公开 30+

377K 标注

爬取 374万

清洗 45万

3 份 CSV

数据集收集

公开：HuggingFace 收集仇恨言论/攻击性语言/有害内容/多语言基准 4 大类 · 爬取：自主爬取 8 国主流论坛 · 457,706 条清洗后样本 · 统一合并 binary/coarse/fine



110,847 条

150K+ 备选

8 国标签

双轨收集

关键词库建设

公开关键词数据集 + Juror B/C 推理实时提取 · 单字 13,932 / 词组 96,915 · 各国独有违规标签 (SARA/冒犯君主等) · sensitive_words_labeled.csv



30+ 论文

16 编码器

12 护栏

双路径

8 国 Adapter

模型调研与训练

XLM-R / mDeBERTa / SEA-LION / 本土 BERT 全面调研 · 方案一：冻结底层 8 层 + Focal Loss · 方案二：LoRA r=16 α =32 ~25MB/国 · 8 国独立训练



内容审核智能体 POC

Multi-Agent Content Moderation System

- FastAPI + LangGraph 双层架构
- 热路径 6 层预筛 + 冷路径 4 Agent DAG
- 文本三层漏斗 + 图像四步处理
- 离线数据飞轮 + 评估基准体系
- 源码 + 架构文档 + 部署指南



AI Agent 安全洞察

AI Agent Security Insights

- AI Agent 安全风险全景分析
- 提示注入/工具滥用/数据泄露等威胁建模
- 安全防护策略与最佳实践建议
- 胶片 presentation 形式交付



Agent 安全技术文档

Agent Security Technical Documentation

- Agent 安全架构设计文档
- 安全审计与评估方法论
- 防护机制实现细节与测试报告
- 后续安全运营与迭代规划

试用期总结与思考

工作成果回顾、经验沉淀与个人成长反思

03

小语种审核能力建设路径

- ▶ 语种调研：评估目标市场语言分布、文化特性与内容风险画像
- ▶ 人才储备：建立小语种审核人才招募、培训与考核体系
- ▶ 标准建设：制定多语种内容安全审核标准与操作规范
- ▶ 工具平台：搭建适配小语种的内容审核工具与自动化 pipeline
- ▶ 质量管控：建立多语种审核质量抽检与持续优化机制

关键成果

能力储备关键成果

- ▶ 完成 8 个国家 / 10+ 语种的内容安全能力储备调研
- ▶ 建立小语种审核人才库，覆盖全部目标语种
- ▶ 输出多语种内容安全审核标准文档与培训材料
- ▶ 搭建小语种内容审核流程，实现从 0 到 1 的能力落地
- ▶ 形成可复用的语种能力建设 SOP，支持快速扩展

核心数据

10+

覆盖语种

8

覆盖国家

5

覆盖区域

0→1

能力建设

下一步工作目标与计划

未来工作方向、阶段目标与实施路径规划

04

+ 工作输出 · 壹

此处添加下一步工作目标与计划内容

+ 工作输出 · 贰

此处添加下一步工作目标与计划内容

+ 工作输出 · 叁

此处添加下一步工作目标与计划内容

+ 工作输出 · 肆

此处添加下一步工作目标与计划内容

结语

总结与展望

- ▶ 已完成五大区域、八个重点国家的小语种内容安全能力储备
- ▶ 建立了从调研到落地的完整能力建设方法论
- ▶ 形成可复用的标准化流程，支持未来快速扩展新市场
- ▶ 持续迭代优化，推动小语种审核能力向更高成熟度发展

感谢聆听

期待各位专家的指导与建议